Rapport de prétraitement

Prédiction du prix de location d'un appartement

Projet Machine Learning – Orange Digital Center

Datasets : apartments_for_rent_classified_10K et 100K

Informations clés

Responsable du prétraitement : Baye Serigne Seck

Date : 10 novembre 2026

Scripts : src/preprocessing.py et src/generate_report.py

Synthèse

99 278	**97**
annonces nettoyées (100K)	variables explicatives
0	**84**
valeur manquante	doublons supprimés

Le jeu de données 100K contient 99 492 annonces brutes et 168 860 valeurs manquantes. Après nettoyage, 99 278 annonces sont conservées, soit 99,8 % des données initiales. Les 214 lignes écartées correspondent à des doublons, des annonces non résidentielles ou non mensuelles, des prix ou surfaces incohérents et des valeurs extrêmes. Toutes les valeurs manquantes ont été traitées et les variables catégorielles ont été encodées pour la modélisation.

Sommaire

Synthèse 2

1. Contexte et objectif 4

2. Données sources 4

3. Méthodologie de prétraitement 5

3.1 Nettoyage de base 5

3.2 Gestion des valeurs manquantes 5

3.3 Traitement des valeurs aberrantes 6

3.4 Création de variables 6

3.5 Encodage et standardisation 6

4. Résultats du prétraitement 6

4.1 Bilan du nettoyage 6

4.2 Distribution du prix 7

4.3 Relation entre surface et prix 7

4.4 Corrélations 7

4.5 Analyse par État 8

4.6 Équipements et animaux 9

4.7 Statistiques descriptives 9

5. Variables disponibles pour la modélisation 9

6. Fichiers générés 10

7. Limites et recommandations 10

8. Conclusion 10

1. Contexte et objectif

Ce rapport documente l'étape de prétraitement du projet de prédiction du prix de location d'un appartement. L'objectif est de transformer les données brutes initiales en un jeu de données propre, cohérent et directement exploitable par les modèles de Machine Learning.

Le travail couvre la gestion des valeurs manquantes, la suppression des doublons, le traitement des valeurs aberrantes, l'encodage des variables catégorielles, la création de variables dérivées et la préparation des variables explicatives X. Deux jeux de données sont traités : le jeu 10K, utilisé pour les essais rapides, et le jeu 100K, qui constitue la base principale du projet.

2. Données sources

Les fichiers sources sont au format CSV, séparés par des points-virgules et encodés en Latin-1. Le jeu 100K contient 99 492 lignes et 22 colonnes. Le jeu 10K est un échantillon de 10 000 lignes issu du même schéma.

Dataset	Fichier source	Lignes	Colonnes	Encodage
10K	apartments_for_rent_classified_10K.csv	10 000	22	Latin-1
100K	apartments_for_rent_classified_100K.csv	99 492	22	Latin-1

Tableau 1. Description des fichiers sources.

Groupe	Variables
Identifiant	id
Cible	price
Numériques	bathrooms, bedrooms, square_feet, latitude, longitude
Catégorielles	category, currency, fee, price_type, has_photo, pets_allowed, cityname, state, source
Texte	title, body, amenities
Temporelle	time (timestamp Unix)

Tableau 2. Groupes de variables du fichier brut.

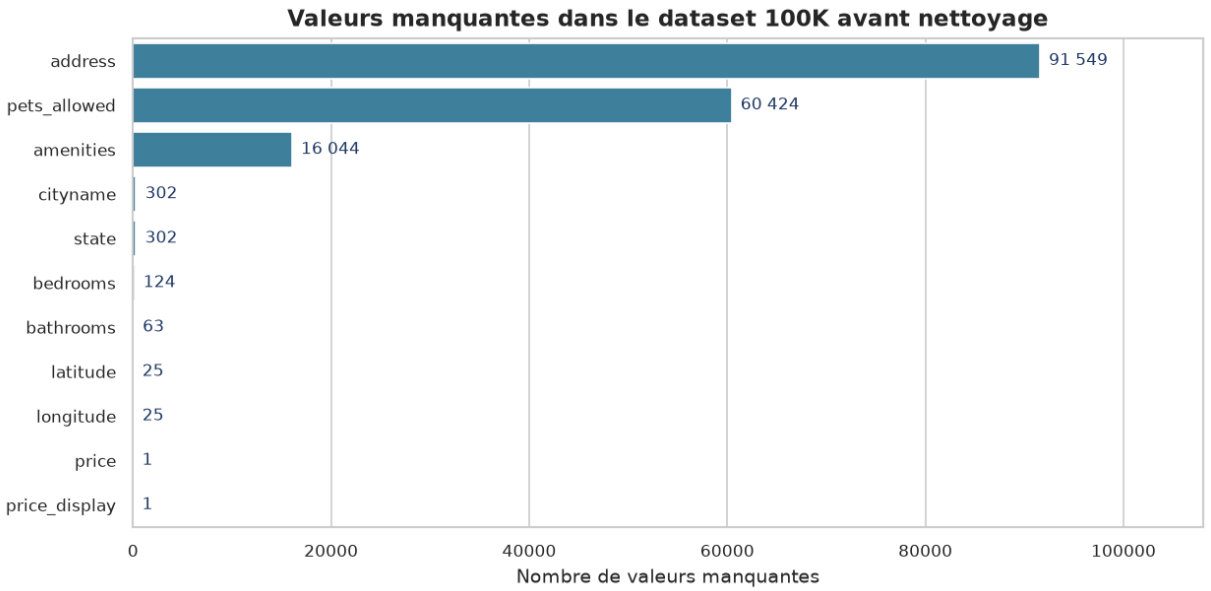


Figure 1. Les variables les plus incomplètes sont l'adresse, les animaux autorisés et les équipements. Les colonnes cityname, state, latitude et longitude ne présentent que quelques valeurs manquantes.

3. Méthodologie de prétraitement

3.1 Nettoyage de base

Le nettoyage commence par la suppression des doublons exacts, puis par le filtrage des annonces qui ne correspondent pas au problème étudié. Seules les annonces de la catégorie appartement, avec un prix mensuel, un prix strictement positif et une surface strictement positive, sont conservées. Les valeurs extrêmes sont ensuite retirées selon les seuils présentés ci-dessous.

Étape	Lignes restantes	Supprimées
Données brutes	99 492	-
Doublons exacts	99 408	84
Catégorie appartement	99 347	61
Prix mensuel	99 343	4
Prix strictement positif	99 342	1
Surface strictement positive	99 342	0
Surface inférieure ou égale à 10 000	99 337	5
Prix entre 200 et 15 000	99 314	23
Prix au pied carré entre 0,3 et 10	99 285	29
Chambres entre 0 et 6	99 278	7
Salles de bain entre 0 et 6	99 278	0

Tableau 3. Filtres appliqués séquentiellement au dataset 100K.

3.2 Gestion des valeurs manquantes

Les valeurs manquantes numériques sont imputées par la médiane afin de limiter l'influence des distributions asymétriques. Les valeurs manquantes géographiques sont imputées par la médiane de l'État, puis par la médiane globale lorsque l'État est inconnu. Les variables catégorielles reçoivent une modalité explicite.

Variable	Règle appliquée
amenities	Valeur manquante conservée comme information absente ; création de l'indicateur amenities_provided.
bedrooms	Imputation par la médiane globale.
bathrooms	Imputation par la médiane conditionnelle au nombre de chambres, puis par la médiane globale.
cityname, state	Remplacement par la modalité Unknown.
latitude, longitude	Imputation par la médiane de l'État, puis par la médiane globale.
pets_allowed	Remplacement par No pets après normalisation des valeurs None.
has_photo	Remplacement par No.

Tableau 4. Règles d'imputation des valeurs manquantes.

3.3 Traitement des valeurs aberrantes

Les seuils ci-dessous visent à conserver les annonces plausibles tout en supprimant les valeurs manifestement erronées ou extrêmes. Le prix au pied carré est utilisé uniquement comme filtre de cohérence : il est supprimé ensuite pour éviter toute fuite d'information provenant de la cible.

Variable	Plage conservée
Prix mensuel	200 à 15 000 USD
Surface	Inférieure ou égale à 10 000 pieds carrés
Prix au pied carré	0,3 à 10 USD
Chambres	0 à 6
Salles de bain	0 à 6

Tableau 5. Seuils de détection des valeurs aberrantes.

3.4 Création de variables

- **Équipements :** 27 indicateurs binaires (parking, piscine, salle de sport, etc.), ainsi que amenities_count et amenities_provided.
- **Animaux :** has_cats et has_dogs à partir de la variable pets_allowed.
- **Dates :** listing_date, listing_year, listing_month et listing_dayofweek à partir du timestamp.
- **Variables dérivées :** is_studio et total_rooms (chambres plus salles de bain).
- **Localisation :** latitude, longitude, encodage one-hot de l'État et fréquence de la ville.
- **Source :** encodage par fréquence de la variable source.

3.5 Encodage et standardisation

Les variables catégorielles à faible cardinalité sont encodées en one-hot, notamment l'État et le type de photo. La ville, qui possède une forte cardinalité, est encodée par sa fréquence d'apparition et complétée par la latitude, la longitude et l'État. La source est également encodée par fréquence. Une version standardisée des variables numériques est fournie pour les modèles sensibles à l'échelle, tandis que les indicateurs binaires restent inchangés.

4. Résultats du prétraitement

4.1 Bilan du nettoyage

Indicateur	Avant	Après
Lignes	99 492	99 278
Colonnes après nettoyage	22	51
Variables explicatives X	-	97
Valeurs manquantes	168 860	0
Doublons exacts	84	0
États distincts	51	52
Villes distinctes	2 972	2 973

Tableau 6. Comparaison avant et après prétraitement (dataset 100K).

Note : la modalité Unknown ajoutée pour les valeurs manquantes de cityname et state explique l'augmentation du nombre d'États et de villes distincts après nettoyage.

4.2 Distribution du prix

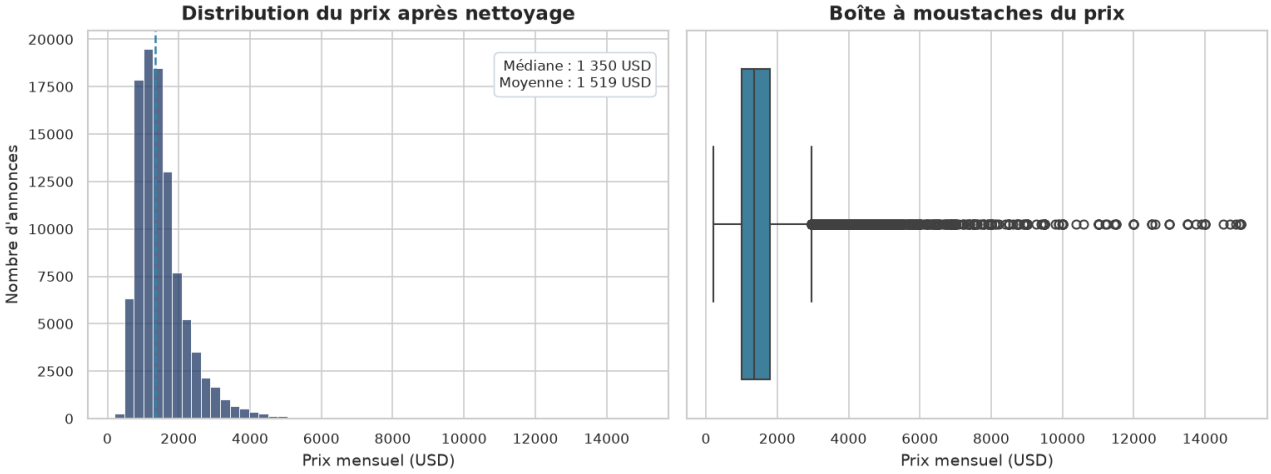


Figure 2. Distribution du prix après nettoyage. La distribution reste asymétrique à droite, avec une médiane de 1 350 USD et une moyenne de 1 520 USD.

4.3 Relation entre surface et prix

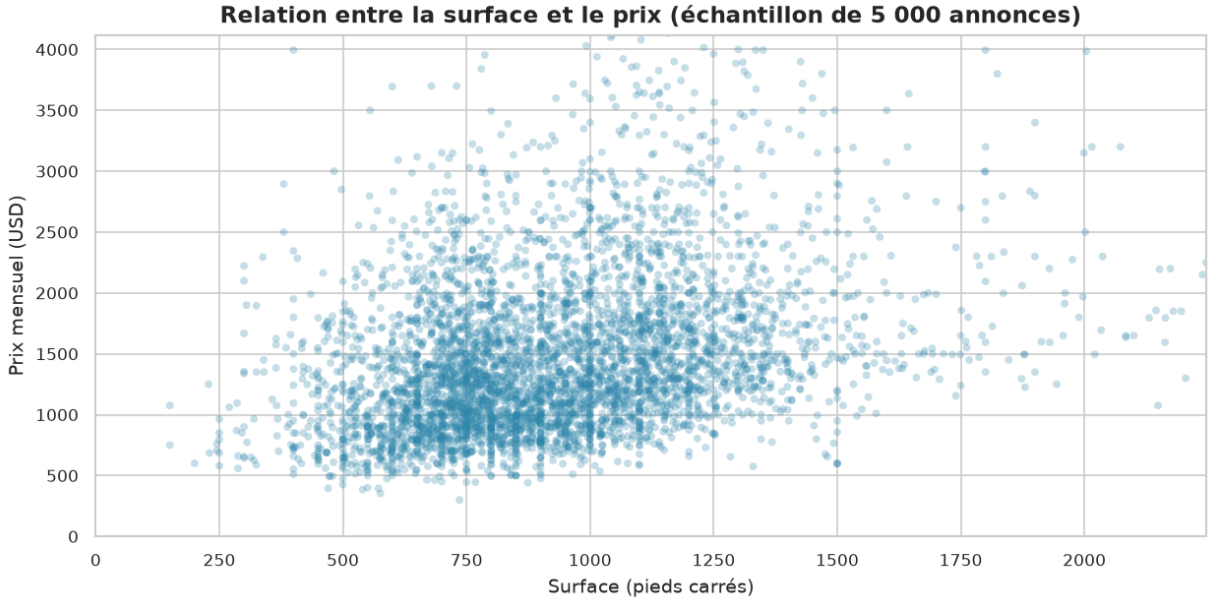


Figure 3. Le prix tend à augmenter avec la surface, mais la dispersion reste importante à surface égale, ce qui justifie l'utilisation d'autres variables explicatives.

4.4 Corrélations

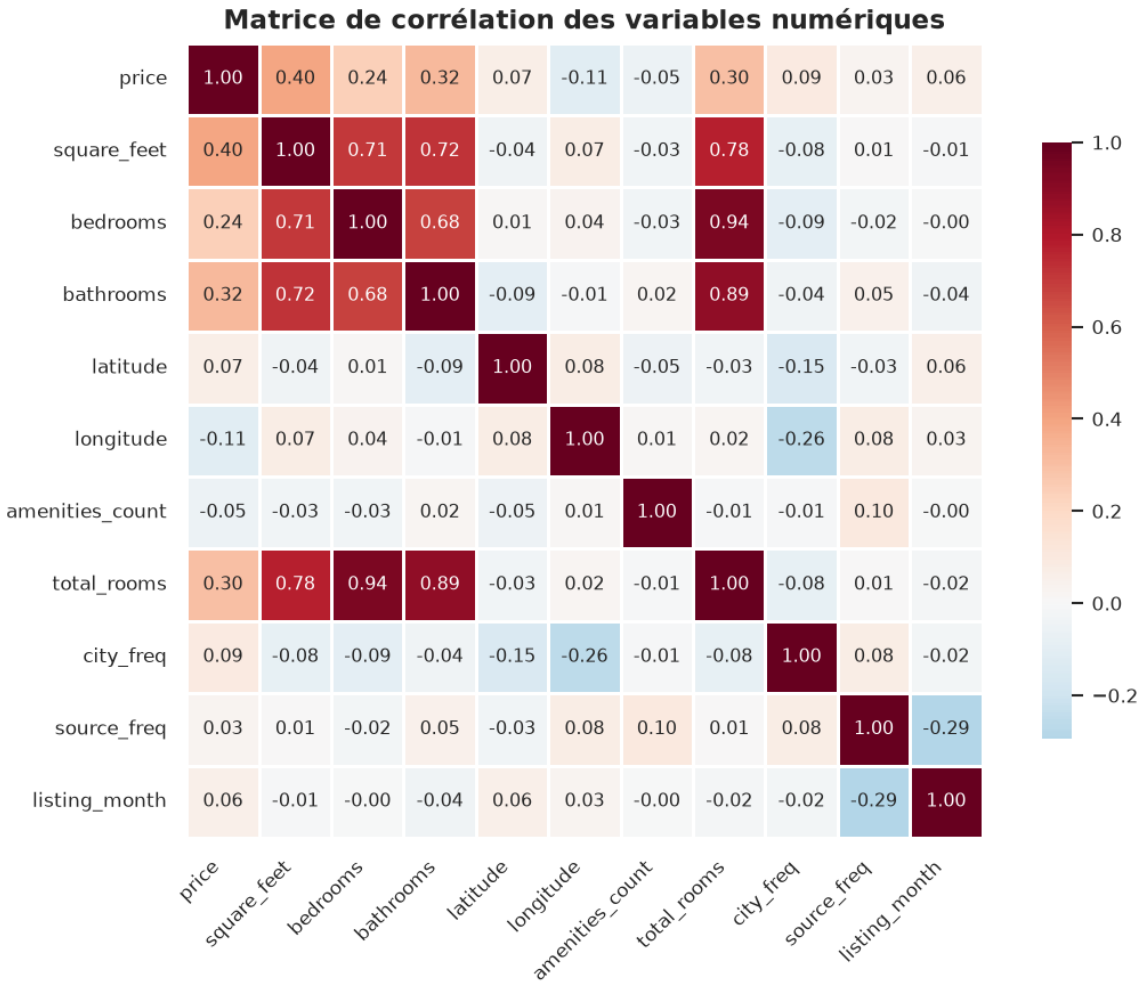


Figure 4. La surface, le nombre de chambres et le nombre de salles de bain présentent les corrélations positives les plus fortes avec le prix. La latitude et la longitude apportent une information complémentaire sur la localisation.

4.5 Analyse par État

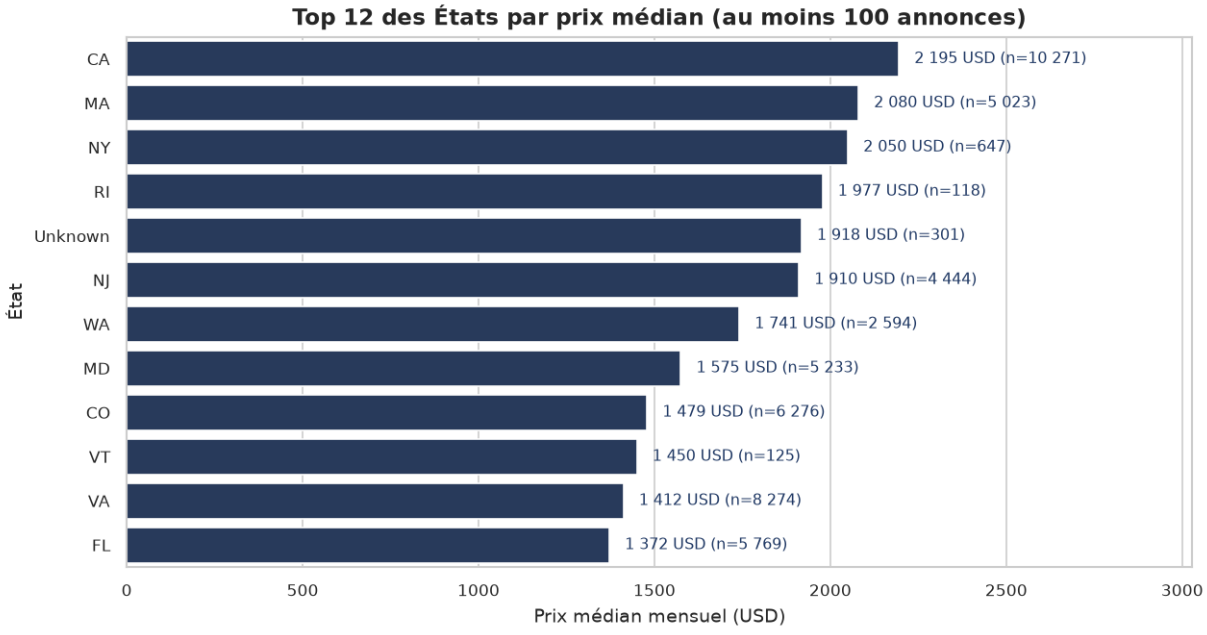


Figure 5. Les prix médians varient fortement selon l'État. Cette variable est donc pertinente pour la modélisation et a été encodée en one-hot.

4.6 Équipements et animaux

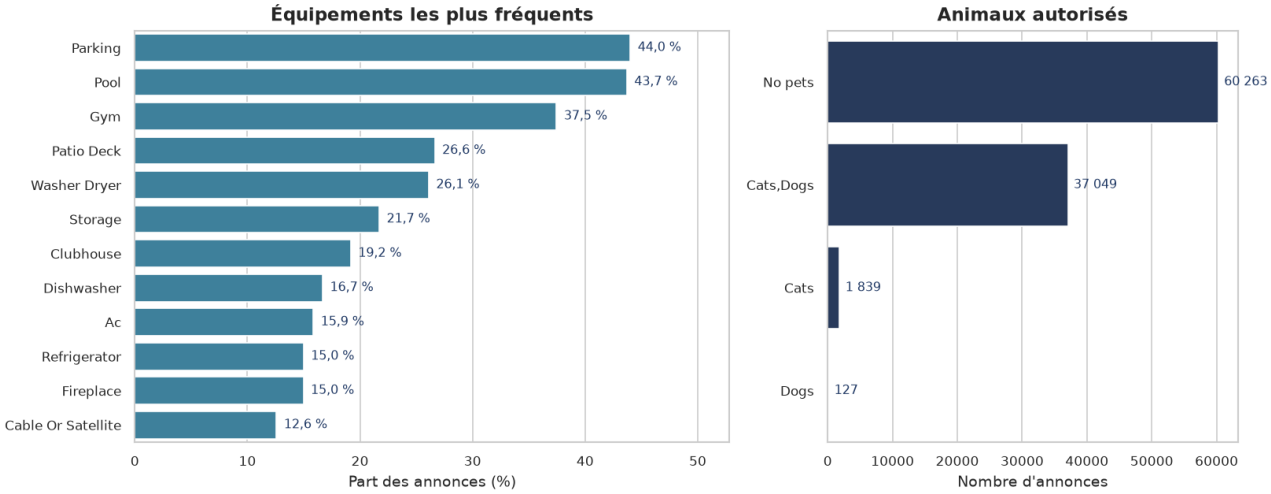


Figure 6. Le parking, la piscine et la salle de sport sont les équipements les plus fréquents. La majorité des annonces ne précise pas d'animaux autorisés.

4.7 Statistiques descriptives

Variable	Moyenne	Médiane	Écart-type	Min	Max
price	1 520	1 350	796	200	15 000
square_feet	954	900	355	101	9 998
bedrooms	1,73	2,00	0,75	0,00	6,00
bathrooms	1,44	1,00	0,54	1,00	6,00
amenities_count	3,66	3,00	3,30	0,00	18,00
total_rooms	3,17	3,00	1,18	1,00	12,00

Tableau 7. Statistiques descriptives des principales variables après nettoyage.

5. Variables disponibles pour la modélisation

La matrice X contient uniquement des variables numériques et ne contient pas la cible. Les variables sont réparties en trois groupes : les variables numériques continues, les indicateurs binaires et les modalités one-hot des États.

Groupe	Nombre	Exemples
Variables numériques	12	square_feet, bathrooms, latitude, city_freq, source_freq
Indicateurs binaires	34	amenity_parking, has_cats, is_studio, photo_Yes
États en one-hot	51	state_CA, state_NY, state_TX
Total	97	X_100K.csv.gz

Tableau 8. Composition de la matrice des variables explicatives (100K).

Pour le jeu 10K, la matrice X contient 96 variables et 9 974 lignes. Les fichiers correspondants suivent la même organisation que ceux du jeu 100K.

6. Fichiers générés

Les livrables du prétraitement sont les matrices de variables explicatives X. Les fichiers de données nettoyées complètes et les fichiers de cible y ne font pas partie des livrables. Les matrices sont compressées au format .csv.gz afin de réduire l'espace occupé et se lisent directement avec pandas.

Fichier	Contenu	Dimensions	Taille
X_100K.csv.gz	Variables explicatives encodées (100K)	99 278 x 97	1,9 Mo
X_100K_scaled.csv.gz	Variables explicatives standardisées (100K)	99 278 x 97	2,0 Mo
X_10K.csv.gz	Variables explicatives encodées (10K)	9 974 x 96	0,2 Mo
X_10K_scaled.csv.gz	Variables explicatives standardisées (10K)	9 974 x 96	0,2 Mo

Tableau 9. Fichiers de variables explicatives produits par le script de prétraitement.

Exemple de lecture : pd.read_csv('data/processed/X_100K.csv.gz').

7. Limites et recommandations

- **Équipements manquants :** une valeur manquante ne signifie pas que l'équipement est absent. L'indicateur amenities_provided permet de distinguer les deux situations.
- **Forte cardinalité :** la ville est encodée par fréquence et complétée par la latitude, la longitude et l'État. Un encodage par cible pourra être testé avec validation croisée.
- **Seuils d'aberrations :** les seuils sont fixes et adaptés au marché américain. Ils pourront être ajustés selon les objectifs métier.
- **Asymétrie de la cible :** une transformation logarithmique du prix pourra être testée lors de la modélisation.
- **Standardisation :** la version standardisée est calculée sur l'ensemble des données. Pour une évaluation rigoureuse, le scaler devra être ajusté uniquement sur l'ensemble d'entraînement.
- **Fuite de cible :** le prix au pied carré a été utilisé uniquement pour filtrer les incohérences, puis supprimé de la matrice X.
- **Choix des modèles :** les modèles à arbres peuvent utiliser X_100K.csv.gz directement. Les modèles linéaires utiliseront plutôt X_100K_scaled.csv.gz.

8. Conclusion

Le prétraitement aboutit à un jeu de données propre, sans valeur manquante, avec des variables catégorielles encodées et des variables dérivées pertinentes. Le jeu 100K conserve 99 278 annonces sur 99 492, soit un taux de conservation très élevé. Les fichiers générés sont prêts à être utilisés pour la séparation entraînement/test, l'entraînement des modèles de régression et l'évaluation des performances.

Les prochaines étapes consistent à effectuer le découpage entraînement/test, à entraîner plusieurs modèles de régression, à comparer leurs performances avec les métriques MAE, MSE, RMSE et R^2, puis à identifier le modèle le plus performant.